

# Dokumen Laporan Final Project: **Travel Insurance Prediction**

## DataGigs – (Kelompok) 6:

- Devina
- Hani Kurnia
- Yudanta A
- Mutiara Farianda
- Linda
- RudiYanti



# Latar Belakang Masalah

Tingginya angka pengidap covid pada akhir tahun 2019 cukup memberikan dampak yang signifikan, salah satunya pada travel industry. Berdasarkan data di tahun 2019, ketertarikan nasabah pada travel insurance yang ditawarkan oleh PT. Travelola sebagai salah satu tour & travel company masih berkisar di angka 35,73%.

Penurunan angka pengguna travel karena disebabkan oleh tingginya kekhawatiran masyarakat saat bepergian. PT. Travelola berinisiatif untuk memberikan solusi berupa covid cover pada travel insurance yang ditawarkan dengan harapan dapat meningkatkan jumlah nasabah sehingga dapat terus menstabilkan profit perusahaan.

# Latar Belakang Masalah

PT. DataGigs sebagai konsultan Data Science dari PT. Travelola bertujuan untuk mengoptimalkan peningkatan revenue dari Travel Insurance Package terbaru yang meliputi Covid Cover. Oleh karena itu, PT. DataGigs memiliki objektif untuk untuk:

- Menggunakan analytical approach dengan membentuk sebuah model Machine Learning untuk memprediksi keputusan customer apakah akan membeli Travel Insurance package yang ditawarkan.
- Memberikan Business Recommendation yang tepat setelah analisa.


## **Business Metric:**

Net Revenue Increase.




# Exploratory Data Analysis

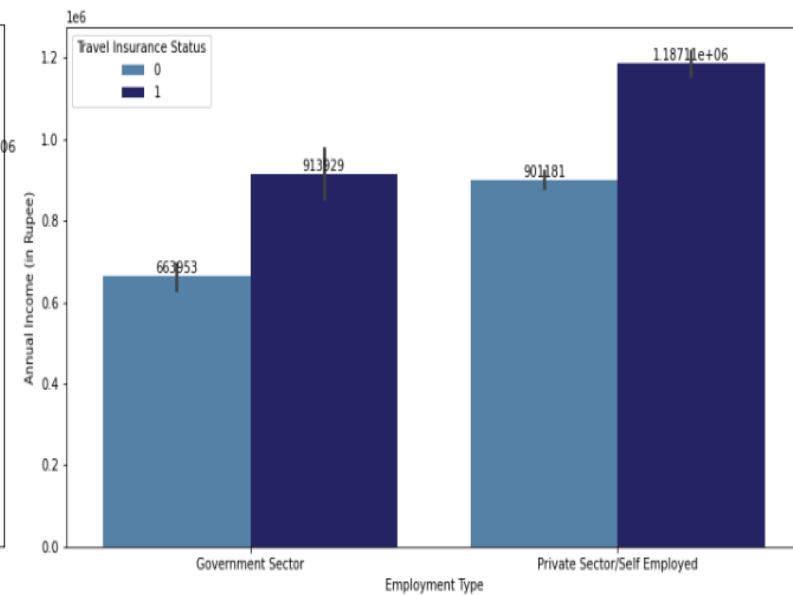
Age



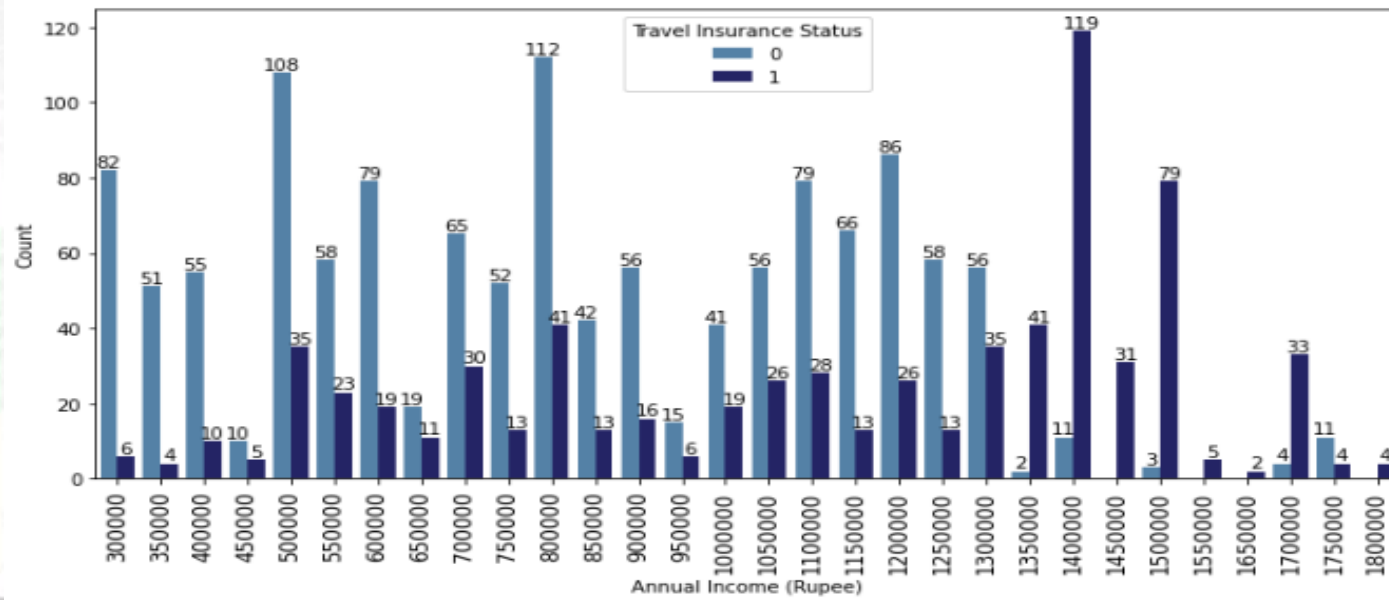
FamilyMembers




Employment Type



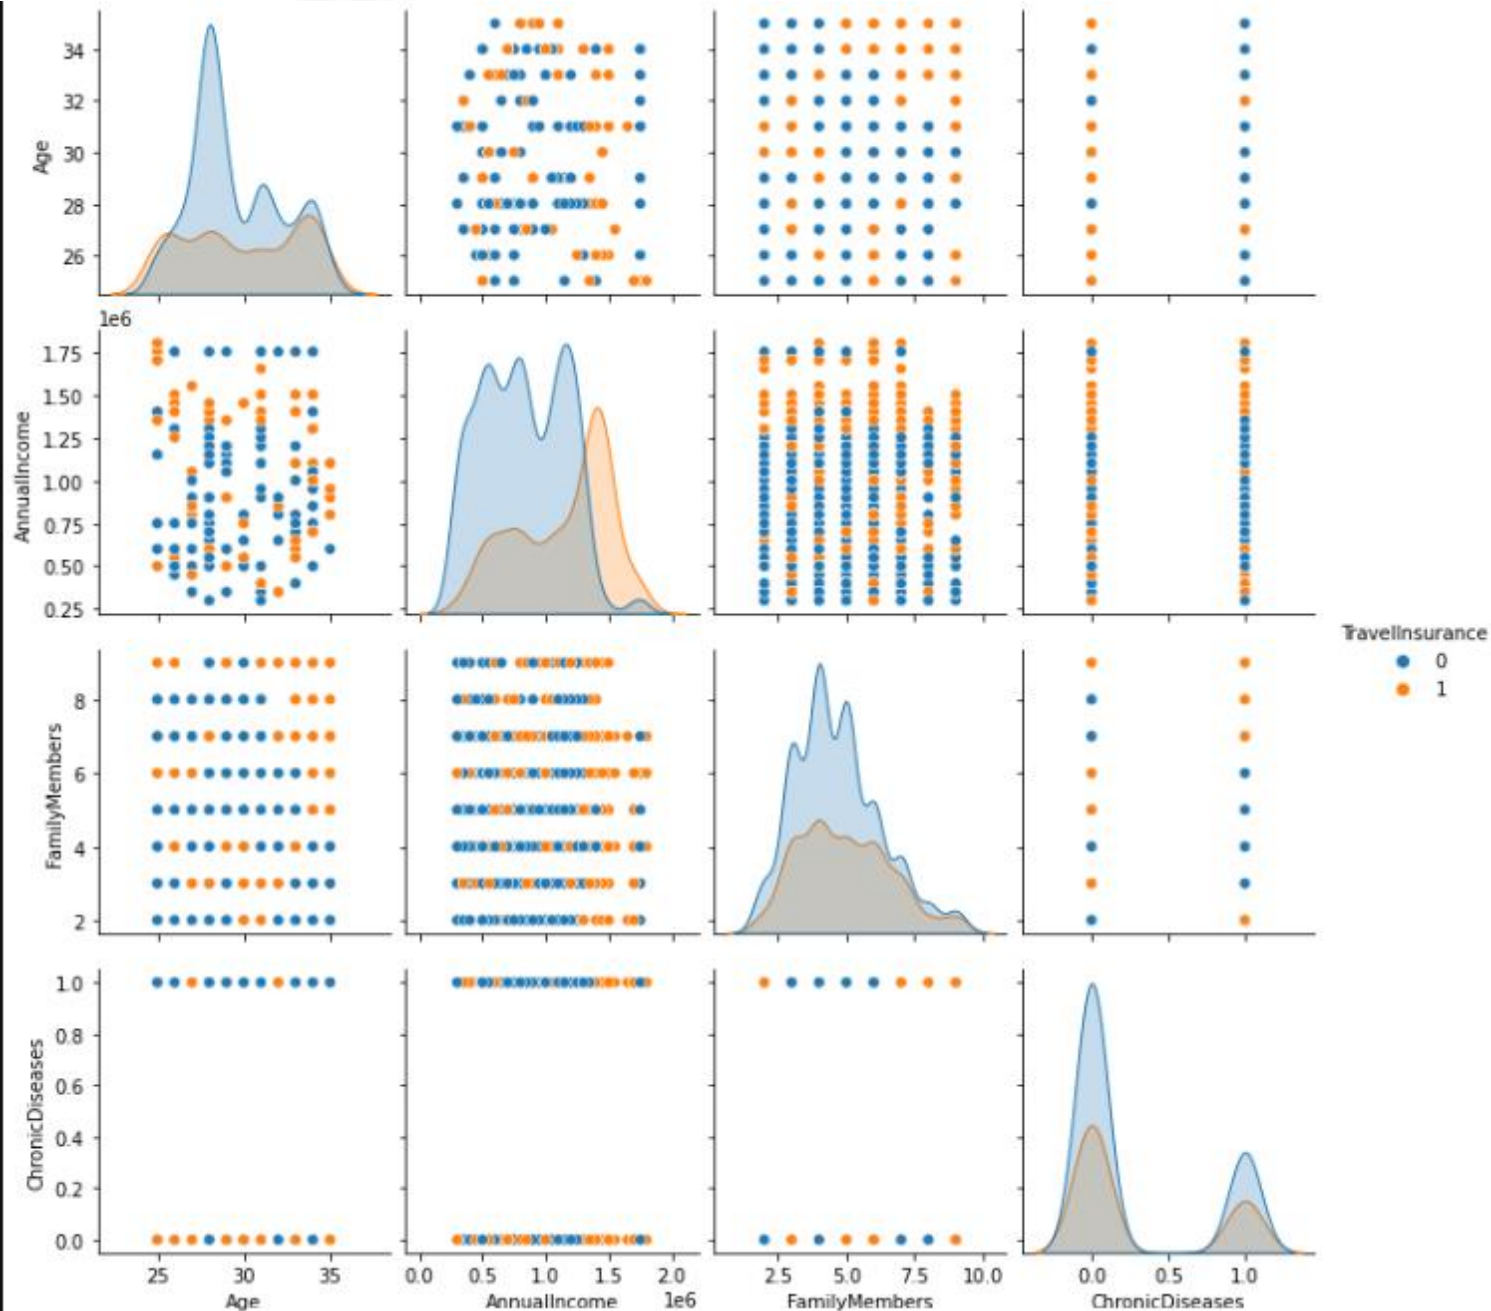
Annual Income



Frequent Flyer



# Exploratory Data Analysis



# Exploratory Data Analysis (Multivariate Analysis)

## NUMERICAL: CORRELATION HEATMAP

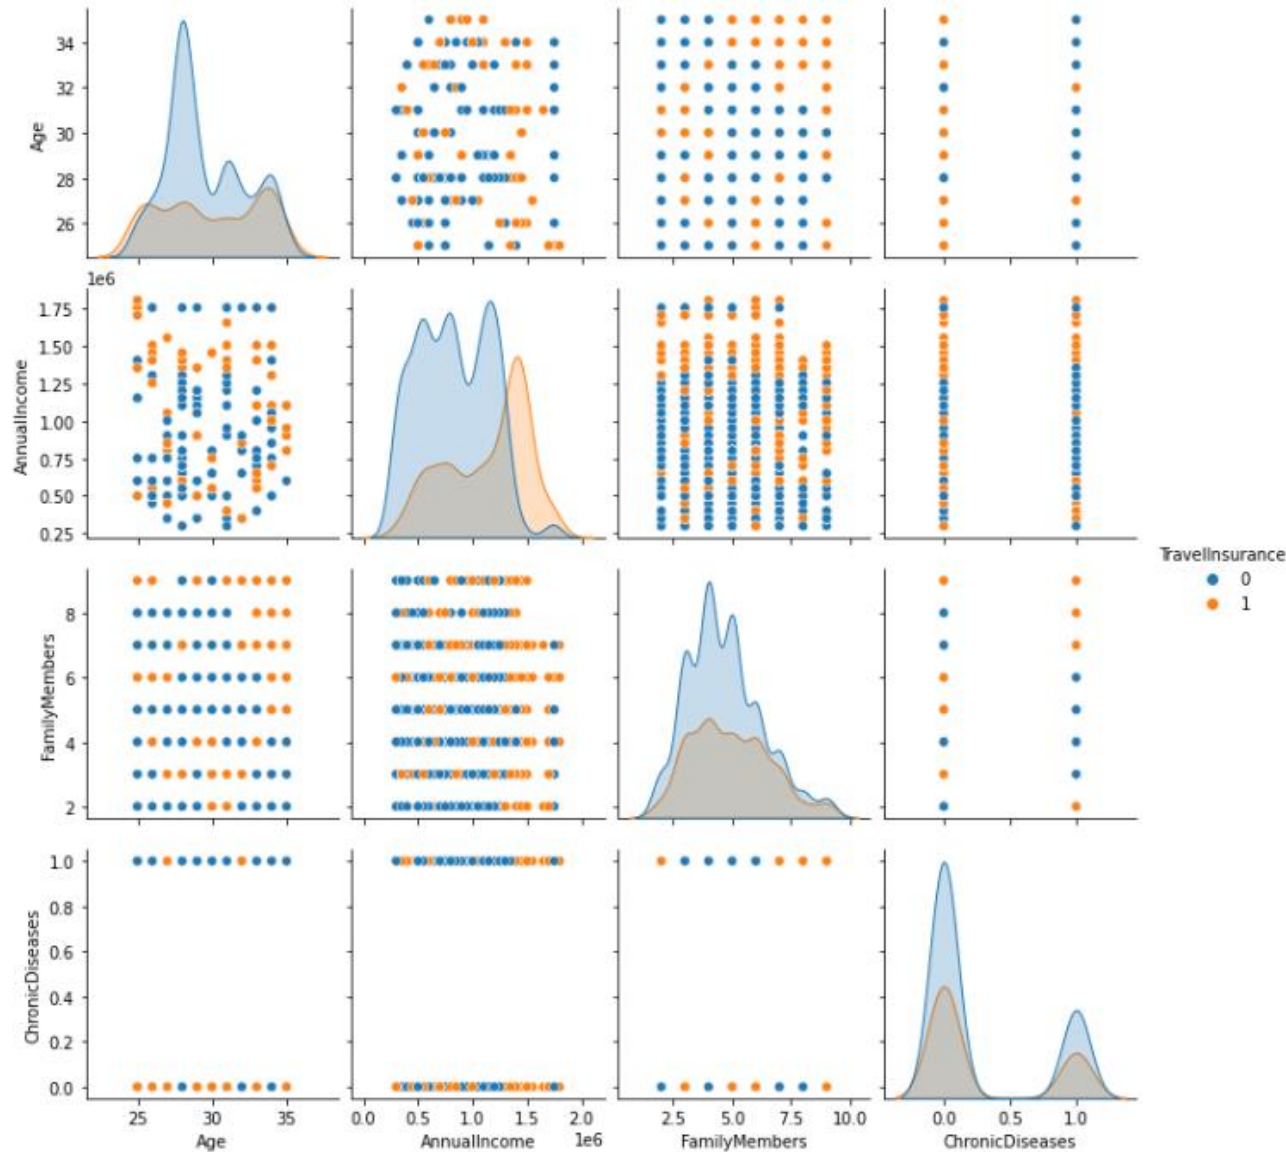


Dari Diagram **Heatmap**, tidak terdapat fitur yang memiliki korelasi yang kuat antara satu sama lain ( $\sim > 0.7$ ) dan hanya terdapat satu korelasi antar fitur yang bernilai positif dan cukup signifikan, yaitu:

- AnnualIncome vs TravelInsurance

# Exploratory Data Analysis (Univariate Analysis)

## NUMERICAL: PAIR PLOT

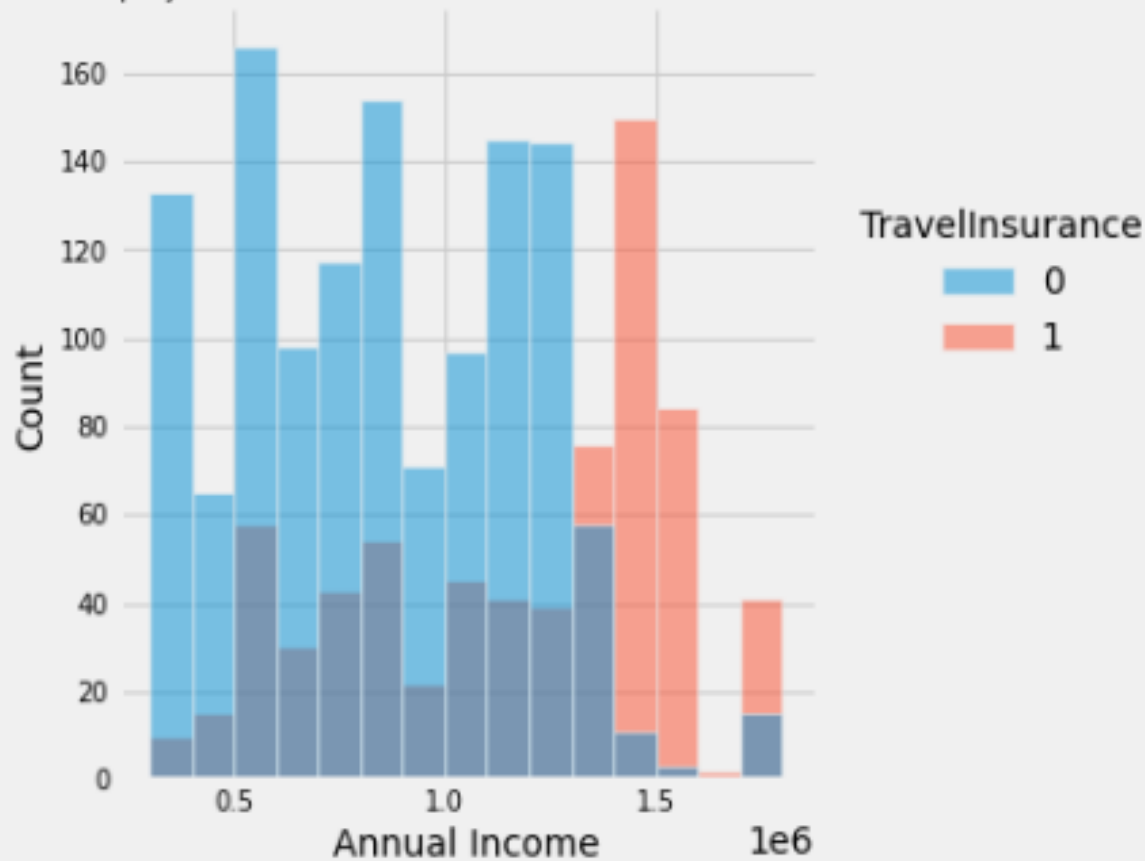


- Berdasarkan **Multivariate Analysis** dengan **Pair Plot**, tidak terlihat pattern yang jelas.



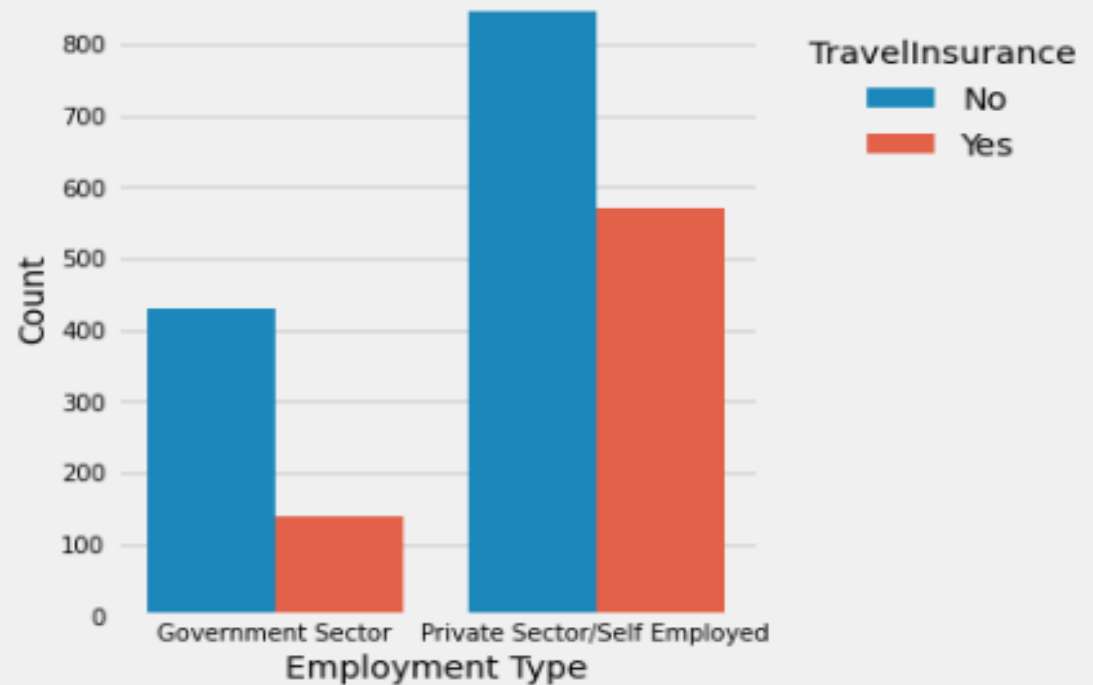
## Besarnya Penghasilan Tahunan Customer Mempengaruhi Pembelian Travel Insurance

Berdasarkan analisis data pada tahun 2019 dengan 1987 sample, dapat di analisa bahwa berdasarkan Penghasilan Tahunan customer yang memiliki penghasilan >1.3juta Rupee memiliki peluang lebih besar untuk membeli asuransi perjalanan.



## Kurangnya Ketertarikan Pegawai Pemerintah Terhadap Asuransi Perjalanan


Berdasarkan EmploymentType, dapat dianalisa bahwa persentase nasabah dari perusahaan swasta memiliki peluang lebih besar untuk menjadi nasabah travel perjalanan, sehingga dapat di jadikan target market kedepannya sebagai sasaran utama. Namun tidak menutup kemungkinan karyawan pemerintahan juga memiliki peluang untuk menjadi calon nasabah asuransi perjalanan, walaupun berdasarkan sample yang digunakan persentasenya lebih kecil. Kita dapat memberikan penawaran khusus sebagai bentuk kerjasama kita dengan staff pemerintahan, harapannya persentase nasabah dari staff pemerintahan ini bisa lebih meningkat untuk kedepannya.





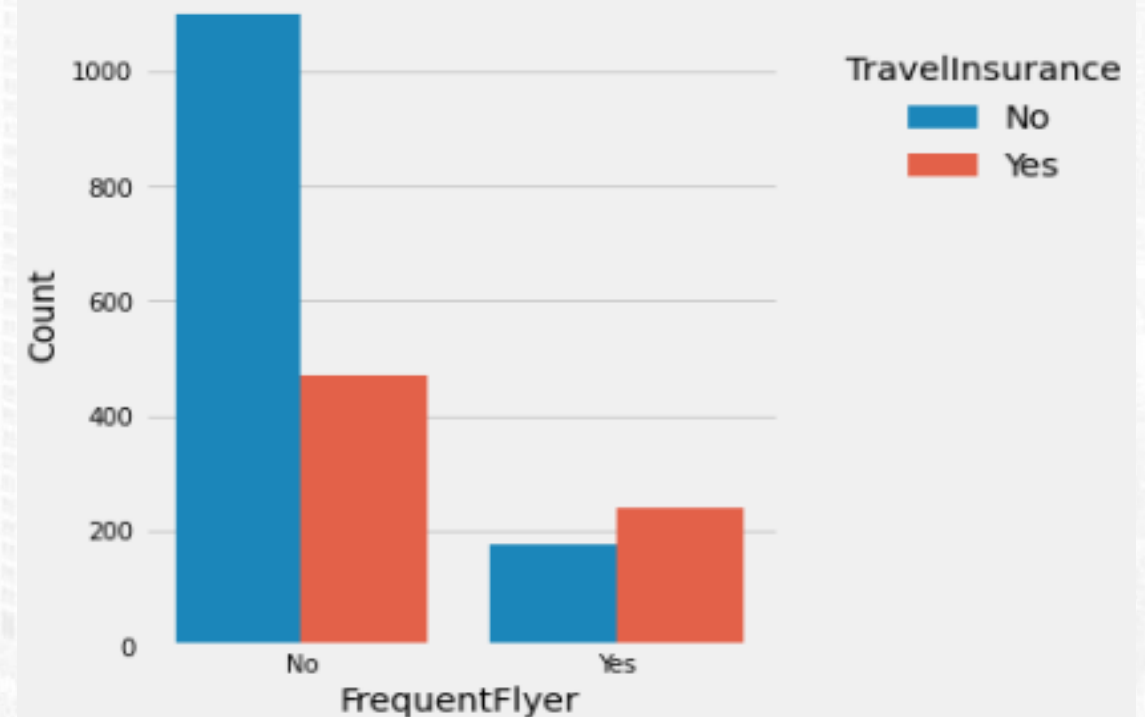
## Jumlah Anggota Keluarga Dapat Mempengaruhi Customer Untuk Membeli Paket Asuransi

Customer dengan anggota keluarga yang banyak memiliki kecenderungan untuk membeli asuransi perjalanan walaupun berdasarkan hasil analisa, jumlah customer yang membeli asuransi perjalanan lebih rendah daripada customer yang tidak membeli. Salah satu perkiraan halangan bagi customer untuk membeli asuransi perjalanan adalah karena income yang lebih terpakai untuk keperluan keluarga. Kita dapat menyusun kembali strategi paket asuransi perjalanan yang ditawarkan dari segi ganti rugi yang akan diberikan berdasarkan jumlah anggota keluarga yang ditanggung oleh customer namun wajar dan tidak merugikan perusahaan, dengan premi/biaya bulanan yang dapat disesuaikan dengan kondisi keuangan.



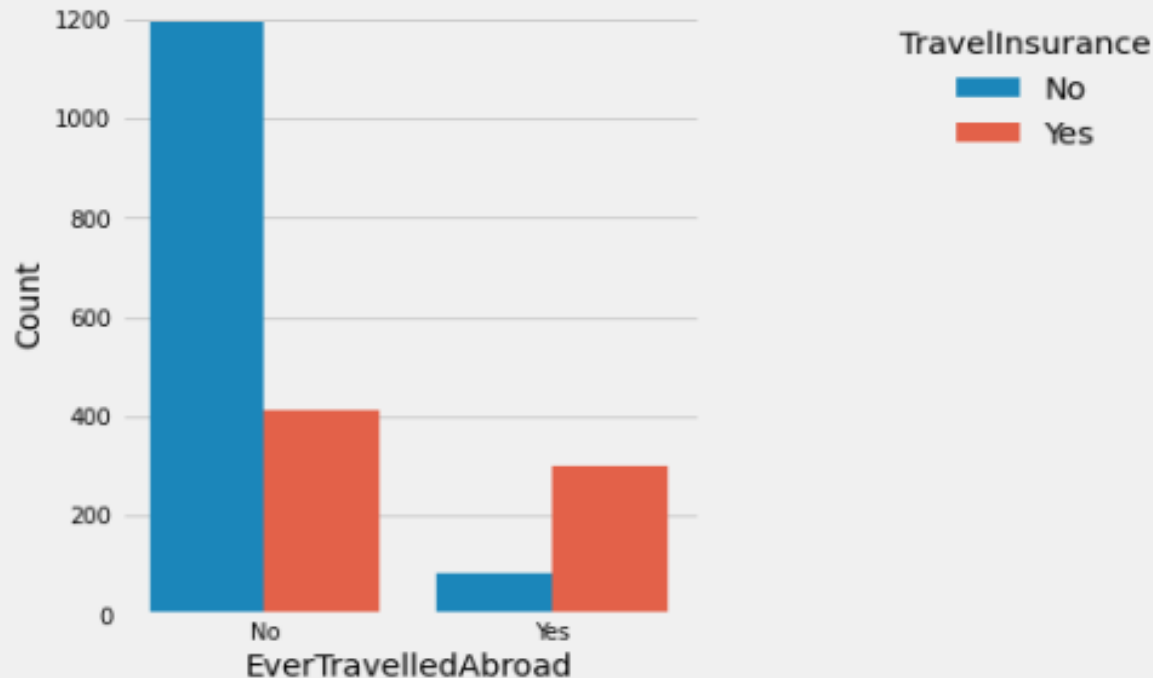
## Frekuensi Perjalanan Customer Mempengaruhi Pertimbangan Pembelian Asuransi Perjalanan

Customer yang memiliki frekuensi perjalanan tinggi lebih cenderung membeli asuransi perjalanan, dimana sebesar 57.31% dari 417 orang customer yang merupakan Frequent Flyer memiliki asuransi perjalanan. Angka ini dapat ditingkatkan dengan menargetkan marketing terhadap kelompok customer tersebut dengan menambahkan edukasi mengenai benefit dan pentingnya memiliki asuransi perjalanan bagi Frequent Flyer. Sedangkan untuk customer yang bukan merupakan Frequent Flyer, sebanyak 30% dari 1570 orang customer diketahui memiliki asuransi perjalanan.



## Kecenderungan Membeli Asuransi Perjalanan oleh Customer yang Pernah Melakukan Perjalanan Internasional

Dari 380 customer yang pernah melakukan perjalanan internasional, sebanyak 78,42% memiliki asuransi perjalanan. Hal ini dapat disebabkan oleh benefit yang menguntungkan dan dapat memberikan rasa aman jika terdapat kendala kesehatan ataupun finansial dalam perjalanan tersebut. Di sisi lain, dari 1607 customer yang belum pernah melakukan perjalanan internasional hanya terdapat 25,64% customer yang memiliki asuransi perjalanan. Kita dapat mempertimbangkan untuk menambahkan benefit yang akan meningkatkan rasa aman dan nyaman dalam perjalanan domestik seperti ganti rugi perubahan jadwal, fasilitas yang didapatkan jika terdapat halangan ataupun kendala dalam melakukan perjalanan, dan sejenisnya.



# Data Cleansing

## (Handling Missing Values & Duplicated Data)

### Handle Missing Value

```
# Periksa nilai kosong fitur numerikal
df.isna().any()
```

```
Age                False
Employment Type    False
GraduateOrNot      False
AnnualIncome       False
FamilyMembers      False
ChronicDiseases    False
FrequentFlyer      False
EverTravelledAbroad False
TravelInsurance    False
dtype: bool
```

```
# Periksa nilai kosong fitur kategorikal
df.isnull().any()
```

```
Age                False
Employment Type    False
GraduateOrNot      False
AnnualIncome       False
FamilyMembers      False
ChronicDiseases    False
FrequentFlyer      False
EverTravelledAbroad False
TravelInsurance    False
dtype: bool
```

Tidak terdapat missing values pada dataset sehingga tidak perlu dilakukan imputasi data.

### Handle Duplicated Data

```
df.duplicated().sum()
```

738

```
# drop duplicated rows
print(f'Jumlah row duplicated sebelum dihapus {df.duplicated().sum()}')
df.drop_duplicates(inplace=True)
print(f'Jumlah row duplicated setelah dihapus {df.duplicated().sum()}')
```

Jumlah row duplicated sebelum dihapus 738

Jumlah row duplicated setelah dihapus 0

```
print(f'Jumlah row tanpa data duplikat: {df.shape[0]}')
```

Jumlah row tanpa data duplikat: 1249

Dari 1987 baris data, terdapat 738 baris data duplikat.

Dilakukan penghapusan 738 baris data tersebut sehingga jumlah baris data yang tersisa adalah 1249 baris data.



# Data Cleansing

## (Handle Outliers)

```
# Menghapus Outlier dengan IQR
```

```
for i in nums:
    q1 = df[i].quantile(0.25)
    q3 = df[i].quantile(0.75)
    iqr = q3-q1
    low_limit = q1 - (1.5 * iqr)
    high_limit = q3 + (1.5 * iqr)
    filtered_entries = ((df[i] >= low_limit) & (df[i] <= high_limit))
    df = df[filtered_entries]
    print(f'Jumlah baris setelah memfilter outlier feature {i}: {len(df)}')
```

```
Jumlah baris setelah memfilter outlier feature Age: 1249
```

```
Jumlah baris setelah memfilter outlier feature AnnualIncome: 1249
```

```
Jumlah baris setelah memfilter outlier feature FamilyMembers: 1249
```

**Kesimpulan:** Tidak terdapat outliers sehingga tidak ada row yang dibuang.

Tidak terdapat outliers pada dataset yang digunakan.

# Data Cleansing

## (Feature Transformation & Feature Encoding)

### Feature Transformation

Fitur-fitur numerikal yang dimiliki bersifat normal, dengan pembuktian:

- Berdasarkan skewness dari fitur-fitur numerikal lebih kecil dari 1, dapat diketahui bahwa distribusi data bersifat normal.
- Perbedaan antara nilai mean dan median dari fitur-fitur numerikal tidak signifikan, sehingga dapat diasumsikan bahwa distribusi data bersifat normal.

Karena fitur-fitur numerikal bersifat normal, untuk penyeragaman values setiap feature dilakukan normalisasi.

### Feature Encoding

- Dilakukan Label Encoding terhadap fitur: 'Employment Type', 'GraduateOrNot', 'FrequentFlyer', 'EverTravelledAbroad'
- Dilakukan One Hot Encoding terhadap fitur: 'IncomeGroup' (Feature dari Feature Extraction)

# Data Cleansing

## (Class Imbalance)

```
# Memeriksa Class Imbalance
target0 = X_train[y==0]
target1 = X_train[y==1]

print(f'target0 shape: {target0.shape} \nPercentage: {round(target0.shape[0] / (target0.shape[0]+target1.shape[0])*100, 2)}%')
print(f'target1 shape: {target1.shape} \nPercentage: {round(target1.shape[0] / (target0.shape[0]+target1.shape[0])*100, 2)}%')

target0 shape: (616, 11)
Percentage: 61.66%
target1 shape: (383, 11)
Percentage: 38.34%
```

Class Imbalance pada kolom Response (Target) tidak signifikan, sehingga tidak perlu di handling.



# Feature Engineering

## (Feature Selection)

Karena jumlah feature yang dimiliki oleh dataset TravelInsurancePrediction ini hanya sedikit, maka diputuskan untuk menggunakan semua feature yang ada.

Telah dilakukan analisa Chi Square Test untuk melihat korelasi antara feature-feature kategorikal yang ada (Employment Type, GraduateOrNot, ChronicDiseases, FrequentFlyer, EverTravelledAbroad) terhadap target (TravelInsurance). Berdasarkan hasil pengujian antara kolom-kolom kategorikal dengan target (TravelInsurance), kolom yang memiliki korelasi adalah sebagai berikut:

- EmploymentType & TravelInsurance
- FrequentFlyer & TravelInsurance
- EverTravelledAbroad & TravelInsurance

# Feature Engineering

## (Feature Extraction)

Merujuk pada artikel dari [The Times in India](#), diketahui bahwa yang termasuk dengan income kelas menengah di India terdapat pada kisaran 5 lakh - 30 lakh (500,000 Rupees - 3,000,000 Rupees) pada tahun 2020. Dengan jarak hanya 1 tahun dari dataset (tahun 2019), diasumsikan tidak terdapat perbedaan kelas income yang signifikan sehingga informasi dari artikel dapat menjadi pedoman dalam melakukan Feature Extraction.

Karena range income pada dataset hanya berkisar dari 300,000 - 1,800,000, maka pemisahan kelas income untuk Feature Extraction dibagi menjadi:

- Low: Income < 500,000 Rupees
- Medium: Income > 500,000 Rupees dan < 1,500,000 Rupees
- High: Income > 1,500,000 Rupees

# Feature Engineering


## (Ideas for Additional Features)

- **Identitas Customer:** Agar dapat membedakan mana yang merupakan data duplikat atau bukan.
- **Memiliki Asuransi Jiwa/Kesehatan:** Apakah customer memiliki asuransi lainnya. Karena benefit dari asuransi perjalanan adalah mengcover semua biaya yang terjadi hanya pada suatu perjalanan sehingga ada kemungkinan customer yang telah memiliki asuransi lainnya tidak akan tertarik untuk membeli asuransi perjalanan.
- **Responded:** Menginformasikan apakah pihak Travel Insurance sudah pernah melakukan marketing terhadap customer sebelumnya (baik via telepon atau email) dan apakah customer memberikan respon atau tidak.
- **Frequency:** Frekuensi berkunjung customer ke web travel
- **PromotionType:** Kolom yang menginformasikan jenis promosi terhadap customer, dimana: 1. untuk orang yang sudah pernah berlangganan, 2. untuk orang yg belum pernah berlangganan. Promosi yang ditampilkan akan berbeda pada halaman akun pelanggan, 3. untuk orang yang sudah pernah ditawarkan secara langsung oleh pihak Travel Insurance namun belum tertarik untuk menjadi customer yang di nilai sangat berpotensi menjadi nasabah Travel Insurance.



# Feature Engineering

## (Ideas for Additional Features)



Customer yang membeli asuransi perjalanan meningkat secara linear dengan penghasilan tahunannya.

# Modelling (Data Train & Test)

## Data Splitting

```
from sklearn.model_selection import train_test_split
```

```
# Menentukan Fitur dan Target
```

```
X = df.drop(['Age', 'AnnualIncome', 'FamilyMembers', 'TravelInsurance', 'IncomeGroup'], axis=1)
y = df['TravelInsurance']
```

```
# Melihat ukuran fitur dan target
```

```
print(f'Shape of Features: {X.shape}')
print(f'Shape of Target: {y.shape}')
```

```
Shape of Features: (1249, 11)
```

```
Shape of Target: (1249,)
```

```
# Splitting the dataset into Train and Test data
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
print('Shape of train: ', '\n', 'X_train', X_train.shape, 'y_train', y_train.shape)
print('Shape of test: ', '\n', 'X_test', X_test.shape, 'y_test', y_test.shape)
```

```
Shape of train:
```

```
X_train (999, 11) y_train (999,)
```

```
Shape of test:
```

```
X_test (250, 11) y_test (250,)
```

- Pada gambar disamping, kami melakukan pemisahan data training dan testing dengan perbandingan data training sebesar 80% dan data testing sebesar 20%.
- Hasil pemisahan data features training sebanyak 999 baris dengan 11 kolom dan data features testing sebanyak 250 baris dengan 11 kolom.
- Hasil pemisahan data target training sebanyak 999 baris dan data target testing sebanyak 250 baris.

# Modelling (Algoritma Modelling)

	Algorithms	Test Accuracy	Test Precision	Test Recall	Test F1	Train ROC AUC	Test ROC AUC	Crossval Train ROC AUC	Crossval Test ROC AUC
0	Logistic Regression	0.708	0.764706	0.39	0.516556	0.704484	0.669867	0.6991	0.6876
1	k-Nearest Neighbor	0.684	0.632911	0.50	0.558659	0.832057	0.651567	0.8330	0.6561
2	Decision Tree	0.632	0.545455	0.48	0.510638	0.982450	0.584533	0.9807	0.5724
3	Random Forest Classifier	0.636	0.552941	0.47	0.508108	0.982382	0.624533	0.9806	0.6249
4	AdaBoost Classifier	0.748	0.862745	0.44	0.582781	0.760026	0.718867	0.7587	0.7282
5	XGB Classifier	0.676	0.623377	0.48	0.542373	0.964178	0.684533	0.9627	0.6971

Berdasarkan tabel yang disediakan, tampak bahwa ada enam algoritma klasifikasi yang digunakan untuk memprediksi apakah customer akan melakukan pembelian travel insurance pada tahun berikutnya. Algoritma-algoritma tersebut adalah Logistic Regression, k-Nearest Neighbor, Decision Tree, Random Forest, AdaBoost, dan XGBoost.



# Modelling

## (Model Evaluation - Pemilihan dan perhitungan metrics model)

	Algorithms	Test Accuracy	Test Precision	Test Recall	Test F1	Train ROC AUC	Test ROC AUC	Crossval Train ROC AUC	Crossval Test ROC AUC
0	Logistic Regression	0.708	0.764706	0.39	0.516556	0.704484	0.669867	0.6991	0.6876
1	k-Nearest Neighbor	0.684	0.632911	0.50	0.558659	0.832057	0.651567	0.8330	0.6561
2	Decision Tree	0.632	0.545455	0.48	0.510638	0.982450	0.584533	0.9807	0.5724
3	Random Forest Classifier	0.636	0.552941	0.47	0.508108	0.982382	0.624533	0.9806	0.6249
4	AdaBoost Classifier	0.748	0.862745	0.44	0.582781	0.760026	0.718867	0.7587	0.7282
5	XGB Classifier	0.676	0.623377	0.48	0.542373	0.964178	0.684533	0.9627	0.6971

Dari semua model yang sudah diuji coba diperoleh hasil modeling yang paling baik dengan urutan pertama yaitu AdaBoost Classifier pada urutan pertama, Logistic Regression pada urutan kedua, dan XGB Classifier pada urutan ketiga. Dari tiga urutan diatas, kelompok kami memutuskan untuk melakukan Hyperparameter Tuning untuk mengoptimalisasi ketiga model Machine Learning tersebut, dengan pertimbangan ketiga model tersebut memiliki perbandingan hasil metriks Train dan Test ROC AUC yang tidak terlalu jauh (**Best Fit**) untuk model Machine Learning AdaBoost Classifier dan Logistic Regression, sedangkan pemilihan model XGB Classifier dilakukan karena melihat adanya kemungkinan untuk mengecilkan overfitting yang terjadi dengan Hyperparameter Tuning karena model tersebut memiliki perbedaan hasil antara Train dan Test ROC AUC yang tidak paling kecil dibandingkan dengan 3 model lainnya (k-Nearest Neighbor, Decision Tree, Random Forest Classifier).

# Modelling

## (Model Evaluation – Hyperparameter Tuning & Cross Validation (XGB Classifier))

### Before Hyperparameter Tuning

```
Test Accuracy': 0.676,
Test Precision': 0.6233766233766234,
Test Recall': 0.48,
Test F1': 0.5423728813559322,
Train ROC AUC': 0.9641776304635311,
Test ROC AUC': 0.6845333333333333,
Crossval Train ROC AUC': 0.9627,
Crossval Test ROC AUC': 0.6971
```

### After Hyperparameter Tuning

```
Test Accuracy': 0.768,
Test Precision': 0.8888888888888888,
Test Recall': 0.48,
Test F1': 0.6233766233766234,
Train ROC AUC': 0.7809458817944458,
Test ROC AUC': 0.7192333333333334,
Crossval Train ROC AUC': 0.8841,
Crossval Test ROC AUC': 0.7233
```

Setelah melakukan Hyperparameter Tuning terhadap ketiga model yang telah ditentukan sebelumnya (AdaBoost Classifier, Logistic Regression, dan XGB Classifier), model yang memiliki performa terbaik adalah XGB Classifier.

Jarak antara Cross Validation data train dan data test mengecil dan dapat ditoleransi ( $< 20\%$ ), dan performa model meningkat.

Ini menunjukkan bahwa XGBoost memiliki kemampuan yang baik dalam memprediksi apakah customer akan melakukan pembelian travel insurance pada tahun berikutnya dengan tingkat precision yang tinggi dan memiliki nilai recall yang baik, yang menunjukkan bahwa model mampu memprediksi dengan baik customer yang akan melakukan pembelian.

Dengan demikian, XGBoost dapat menjadi pilihan yang baik untuk proses pembuatan machine learning selanjutnya. Ini memberikan business insight bagi perusahaan untuk lebih memahami dan menentukan strategi untuk memaksimalkan pembelian travel insurance dari customer mereka.


# Modeling

## (Confusion Matrix)

Confusion Matrix: Train

```
[[580 36]  
 [196 187]]
```


Text(0.5, 3.7399999999999807, 'Prediction')



Confusion Matrix: Test

```
[[144 6]  
 [ 52 48]]
```

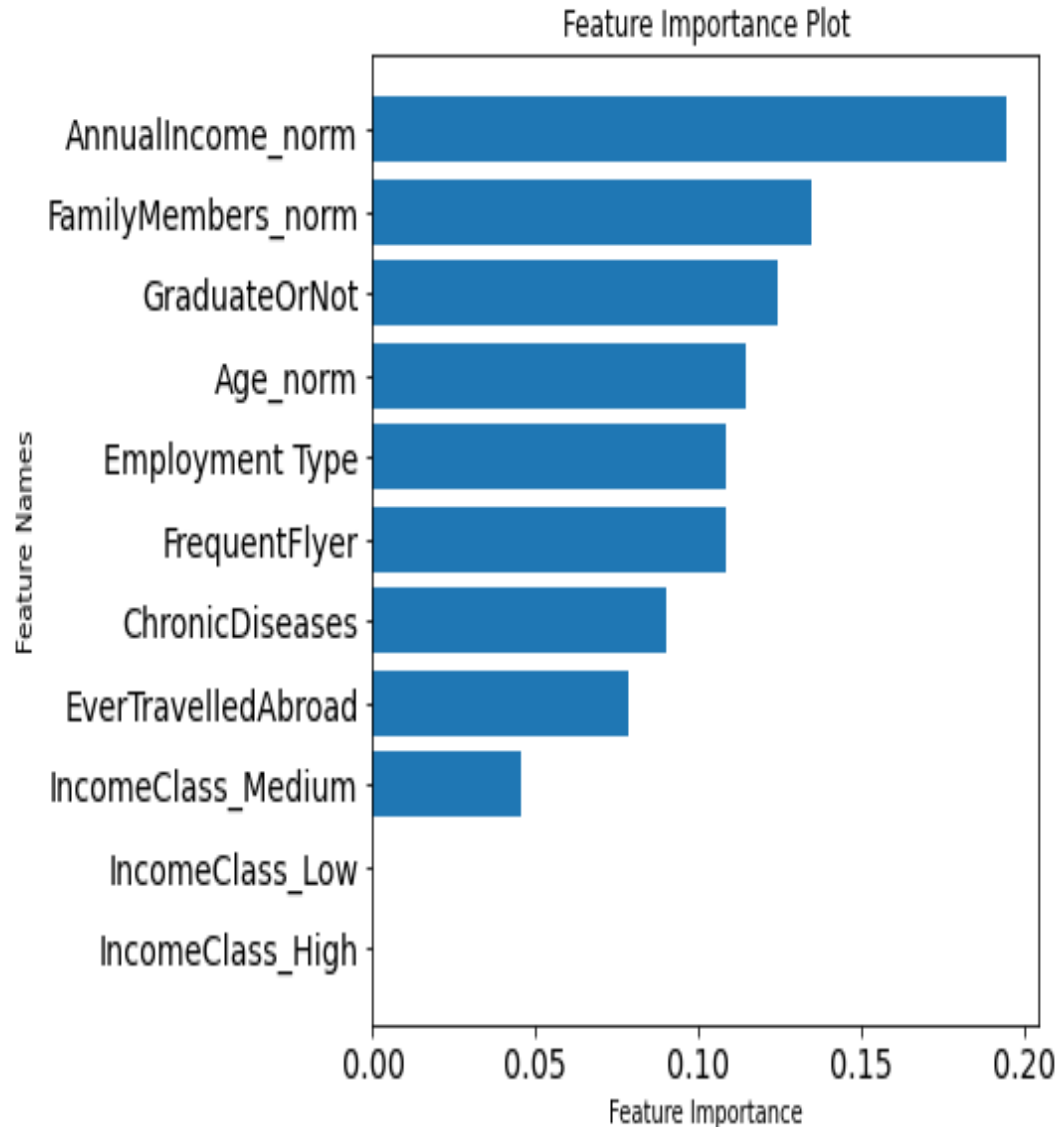
Text(0.5, 3.7399999999999807, 'Prediction')



- ✓ Dari hasil data training yang sudah diprediksi oleh model Machine Learning pada Confusion Matrix: Train diatas , diperoleh hasil prediksi skor ROC AUC sebesar 71,4905%.
- ✓ Dari hasil data testing yang sudah diprediksi oleh model Machine Learning pada Confusion Matrix: Testing diatas, diperoleh hasil prediksi skor ROC AUC sebesar 72.0%
- ✓ Dari percobaan kedua data diatas, dapat disimpulkan bahwa model Machine Learning memiliki skor ROC AUC untuk memprediksi data training dan testing yang bagus dikarenakan gap antara kedua data tersebut cukup kecil.



# Feature Importance (Business Insight)

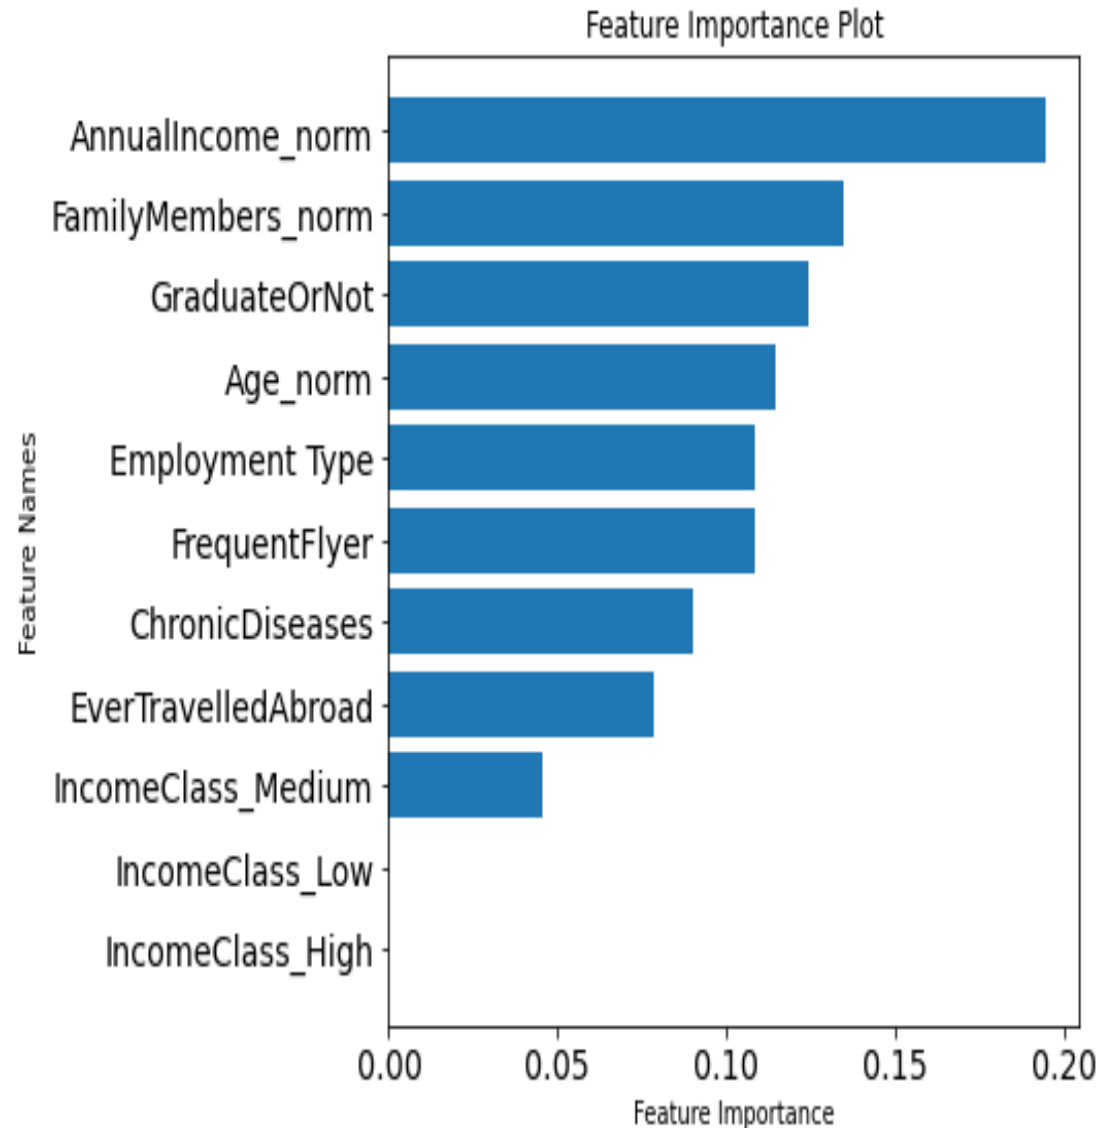


Berdasarkan Grafik Feature Importance di atas, Business Insight yang dapat disimpulkan adalah:

- Penghasilan Tahunan (AnnualIncome\_norm) merupakan faktor terpenting bagi customer dalam pengambilan keputusan untuk membeli asuransi perjalanan. Hal ini wajar karena customer dengan penghasilan yang rendah akan sulit menyisihkan penghasilannya untuk melakukan perjalanan, ataupun membeli asuransi perjalanan. Prioritas penggunaan penghasilan customer akan lebih mendahulukan kebutuhan primer.
- Jumlah Anggota Keluarga (FamilyMembers\_norm) merupakan faktor terpenting kedua setelah faktor Penghasilan Tahunan. Hal ini cukup wajar karena sebanding dengan Penghasilan Tahunan, Jika jumlah anggota keluarga yang merupakan tanggungan dari customer ada banyak, maka prioritas penggunaan penghasilan customer tentunya adalah untuk anggota keluarga terlebih dahulu.



# Feature Importance (Business Insight)



Berdasarkan Grafik Feature Importance di atas, Business Insight yang dapat disimpulkan adalah:

- **Lulusan Pendidikan Tinggi atau Tidak (GraduateOrNot):** Faktor berikutnya yang mempengaruhi keputusan customer dalam membeli asuransi perjalanan adalah status pendidikan customer, dimana kita dapat mengetahui apakah customer merupakan lulusan pendidikan tinggi atau bukan. Customer yang merupakan lulusan pendidikan tinggi diperkirakan mampu memahami resiko yang ada setiap kali melakukan perjalanan, dan memiliki penghasilan yang lebih besar, sehingga dapat mempengaruhi kepurusan customer dalam pengambilan keputusan untuk membeli asuransi perjalanan.
- **FrequentFlyer:** Faktor ini menginformasikan apakah customer merupakan seseorang yang sering melakukan perjalanan. Seorang Frequent Flyer akan memiliki resiko membutuhkan asuransi perjalanan yang lebih tinggi dibandingkan dengan customer yang jarang melakukan perjalanan, sehingga dapat disimpulkan bahwa status Frequent Flyer akan mempengaruhi pengambilan keputusan customer untuk membeli asuransi perjalanan.

## Feature Importance (Business Recommendations: Action Items)

- **Annual Income: Income Based Discount**  
Membuat event discount (sale) untuk target customer berdasarkan informasi income group.  
Contoh:  
Income Group High: 5%  
Income Group Medium: 10%  
Income Group Low: 15%
- **Family Members: Referral Program (Family & Friends)**  
Membuat program referral dimana customer yang telah bergabung dapat menikmati keuntungan tambahan (10% dari harga package yang diambil oleh customer baru untuk Referred Customer, dan 5% dari harga package yang diambil oleh customer baru untuk customer baru itu sendiri).
- **Frequent Flyer: Loyalty Club**  
Membuat program **Loyalty Club** dimana customer yang telah bergabung akan dapat menukarkan point-point yang telah didapatkan dari transaksi-transaksi sebelumnya untuk mendapatkan keuntungan-keuntungan yang ditawarkan.
- **Marketing Strategy: Anchoring Effect Marketing**  
Sebuah teknik marketing yang menggunakan prinsip '**Mental Anchoring**' untuk mempengaruhi persepsi customer mengenai harga sebuah produk atau jasa. Perusahaan akan menetapkan harga tinggi awal dari sebuah produk atau jasa, kemudian menawarkan diskon yang besar untuk menarik customer agar membeli produk kita.

- PT. Travelola sebagai perusahaan yang bergerak dalam bidang Travel dan Travel Insurance di India ingin berkontribusi dalam mendorong publik agar kembali melakukan perjalanan, salah satunya adalah dengan menawarkan asuransi perjalanan yang meliputi pembatalan atau penundaan perjalanan, kehilangan atau pencurian bagasi, keterlambatan atau pembatalan penerbangan, kecelakaan atau sakit, tanggung jawab hukum dan juga **Covid Cover**. Perusahaan juga berharap dengan adanya solusi yang diberikan, perusahaan juga bisa mendapatkan keuntungan dari sisi penjualan asuransi perjalanan.
- Dengan model yang sudah dibuat, diharapkan agar perusahaan dapat memprediksi customer yang akan tertarik untuk membeli asuransi perjalanan yang ditawarkan, sehingga perusahaan dapat menerapkan berbagai strategi untuk meningkatkan keuntungan yang akan didapatkan.
- Dengan penerapan rekomendasi bisnis seperti referral program, loyalty club dan anchoring effect marketing, optimisasi pendapatan perusahaan diharapkan dapat meningkat seoptimal mungkin.